

## L2.1.

*Dowód.* Najpierw pokażemy, że każdą liczbę  $x$  można zapisać w postaci  $smB^c$ .  $s$  to oczywiście znak. Teraz,  $x = mB^c$  (z dokładnością do modułu, ale to nie jest istotne). Skoro tak, to  $m = \frac{x}{B^c}$ , innymi słowy przesuwamy binarną reprezentację  $x$  o  $c$  miejsc w lewo.  $c$  możemy dobrać tak, żeby nasze  $m$  było z przedziału  $[\frac{1}{B}, 1)$ . Oczywiście jest to możliwe, trzeba się tylko trochę zastanowić (przesuwamy przecinek tak, by przed przecinkiem było 0, za przecinkiem będzie 1 i dalej coś, czyli liczba z zakresu  $[\frac{1}{B}, 1)$ ). Wtedy  $m$  mamy już obliczone. Czyli każdego  $x$  możemy przedstawić w tej postaci.

Teraz jednoznaczność.

Założmy nie wprost, że istnieją dwie różne reprezentacje  $x$  w postaci  $smB^c$ . Oczywiście, znak jest stały. Mamy więc, że:

$$x = sm_1B^{c_1} = sm_2B^{c_2} \Rightarrow m_1B^{c_1} = m_2B^{c_2} \Rightarrow \log m_1 + c_1 = \log m_2 + c_2 \Rightarrow \log \frac{m_1}{m_2} = c_2 - c_1$$

- $c_1 = c_2$

$$\log \frac{m_1}{m_2} = 0 \Rightarrow \frac{m_1}{m_2} = 1 \Rightarrow m_1 = m_2$$

Sprzeczność.

- $c_1 > c_2$

$$\log \frac{m_1}{m_2} = c_2 - c_1 \Rightarrow \log \frac{m_1}{m_2} \leq -1 \Rightarrow \frac{m_1}{m_2} \leq \frac{1}{B} \Rightarrow m_1 \leq \frac{1}{B}m_2$$

Teraz musimy skorzystać z tego, że  $m_1, m_2 \in [\frac{1}{B}, 1)$ . Widać już, że mamy sprzeczność, bo żeby  $m_1$  było w dobrym przedziale, to  $m_2$  musiałoby być większe (bądź równe) 1, co jest niemożliwe.

- $c_1 < c_2$

$$\log \frac{m_1}{m_2} = c_2 - c_1 \Rightarrow \log \frac{m_1}{m_2} \geq 1 \Rightarrow \frac{m_1}{m_2} \geq B \Rightarrow m_1 \geq Bm_2$$

Ponownie korzystamy z tego, że  $m_1, m_2 \in [\frac{1}{B}, 1)$ . Żeby  $m_1$  było w dobrym przedziale  $m_2$  musiałoby być mniejsze od  $\frac{1}{B}$ , co jest niemożliwe.

Notka: Każdy logarytm, o którym mowa wyżej, jest o podstawie  $B$

□

L2.2.

$$\textcircled{2} \quad f = \pm (0.1x_2)_2 \cdot 2^{\pm c} \quad x, y, z, c \in \{0, 1\}$$

$$f = \pm \left( \frac{1}{2} + x \cdot \frac{1}{4} + y \cdot \frac{1}{8} + z \cdot \frac{1}{16} \right) \cdot 2^{\pm c} \in \left\{ \frac{1}{2}, 1, 2 \right\}$$

$$f = \pm \left( \frac{16}{32} + x \cdot \frac{8}{32} + y \cdot \frac{4}{32} + z \cdot \frac{2}{32} \right) \cdot a \quad a \in \left\{ \frac{1}{2}, 1, 2 \right\}$$

$x, y, z \in \{0, 1\}$

$$\frac{16}{32} \pm \left\{ \frac{16}{32}, \frac{18}{32}, \frac{20}{32}, \frac{22}{32}, \frac{24}{32}, \frac{26}{32}, \frac{28}{32}, \frac{30}{32} \right\}$$

$$\times \uparrow \frac{10}{10} \left\{ \frac{1}{2}, 1, 2 \right\}$$

$$\pm \left\{ \frac{8}{32}, \frac{9}{32}, \frac{10}{32}, \frac{11}{32}, \frac{12}{32}, \frac{13}{32}, \frac{14}{32}, \frac{15}{32} \right\}$$

$$\pm \left\{ \frac{32}{32}, \frac{36}{32}, \frac{40}{32}, \frac{44}{32}, \frac{48}{32}, \frac{52}{32}, \frac{56}{32}, \frac{60}{32} \right\}$$



$$f \in \left\langle -\frac{60}{32}, -\frac{8}{32} \right\rangle \cup \left\langle \frac{8}{32}, \frac{60}{32} \right\rangle$$

$$f \in \left\langle -\frac{60}{32}, \frac{60}{32} \right\rangle$$

Dla ujemnych symetrycznie. Ogólnie jest 48 liczb zapisywalnych w tym systemie.

Wnioski: Dla dodatnich mamy takie 4 przedziały: pierwszy pusty, każdy kolejny 2 razy rzadszy od poprzedniego.

**L2.3.**

Pokaż, że

$$\frac{|rd(x) - x|}{|x|} \leq 2^{-t}$$

*Dowód.*

$$\frac{|rd(x) - x|}{|x|} = \frac{|sm_t 2^c - sm 2^c|}{|sm 2^c|} = \frac{|(s2^c)(m_t - m)|}{|s2^c m|} = \frac{|m_t - m|}{|m|} \stackrel{(1)}{\leq} \frac{2^{-t}}{2m} \stackrel{(2)}{\leq} 2^{-t}$$

Gdzie:

(1) bo w treści mamy, że  $|m_t - m| \leq \frac{1}{2} 2^{-t}$

(2) bo maksymalizujemy ułamek. Skoro maksymalizujemy ułamek to minimalizujemy licznik.  $m \in [\frac{1}{2}, 1)$ . Czyli  $2m$  może minimalnie wynieść 1. Jeśli ułamek byłby mniejszy, działałoby tym bardziej.  $\square$

**L2.4.**

[Co student PWR o IEEE 754 wiedzieć powinien](#)

TODO: wypisać tutaj różnice. Na pewno IEEE ma specjalne wartości, jak NaN czy Infinity, ale to nie wszystko...

**L2.5.**

Założmy, że maksymalna wartość  $X_{fl} = 2^{64}$  i weźmy  $x = y = 2^{60}$ .

$$\sqrt{x^2 + y^2} = \sqrt{(2^{60})^2 + (2^{60})^2} = \sqrt{2^{120} + 2^{120}} = \sqrt{2^{120}(1 + 1)} = 2^{60} \sqrt{2}$$

$2^{60} \sqrt{2} \in X_{fl}$ . No ale  $2^{120}$  już się nie mieści. Jak moglibyśmy to naprawić?

Założmy, że  $x \geq y$ , jeśli nie to możemy podmienić.

$$\sqrt{x^2 + y^2} = \sqrt{x^2(1 + \frac{y^2}{x^2})} = |x| \sqrt{1 + (\frac{y}{x})^2}$$

Skoro  $x \geq y$  to pod pierwiastkiem mamy maksymalnie dwójkę, więc nie grozi nam nadmiar (bo  $\sqrt{2} \max(x, y) \in X_{fl}$ ). Przerabiamy to na algorytm, co zostawiam jako proste ćwiczenie.

Co do długości euklidesowej, to jeśli wiemy, że zapisuje się ją wzorem

$$||x_n|| = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2}$$

To już możemy łatwo znaleźć analogię do tego co robiliśmy przed chwilą. Wyciągamy największego  $x$  przed pierwiastek. Jeśli  $\sqrt{n} \cdot \max(|x_1|, |x_2|, \dots, |x_n|) \in X_{fl}$



## L2.6.

### 2.1 Utrata cyfr znaczących

Utrata cyfr znaczących występuje, gdy odejmujemy od siebie dwie bliskie sobie liczby zmiennoprzecinkowe. Wtedy na początku otrzymamy dużo zer, a dopiero na dalekim miejscu cyfry znaczące. Jednak ponieważ mantysa jest znormalizowana, to liczba zostanie przesunięta w lewo do pierwszej cyfry znaczącej. Zauważmy jednak, że przesuwając liczbę w lewo w „ogonie” dopiszemy liczby, których nie znamy.

**Przykład:** Miejsce w pamięci na 7 cyfr,  $m_1 = 1,23467890123\dots$ ,  $m_2 = 1,23456789012\dots$

$$m_1 - m_2 = \underbrace{1,234678901\dots}_{\text{tyle mamy w pamięci}} - \underbrace{1,23456789012\dots}_{\text{tyle mamy w pamięci}} = 0,00011111\dots$$

Po przesunięciu otrzymamy: 111  $\underbrace{????}_{\text{te liczby były poza pamięcią}}$

Najczęściej w takim wypadku te nieznane wartości wypełniamy zerami. W tym przypadku popełniamy niewielki błąd, bo tylko o 1111, ale co byłoby, gdyby miało tam się znajdować 9999?

## L2.7.

TODO: Podobno trzeba udowodnić indukcyjnie, że  $x_k = 2^k \sin(\frac{\pi}{2^{k+1}})$

## L2.8.

a)  $x^3 + \sqrt{x^6 + 2017}$ ,

Utrata cyfr znaczących przy dużych ujemnych x-ach.

$$\begin{aligned} \text{a) } (x^3 + \sqrt{x^6 + 2017}) \frac{x^3 - \sqrt{x^6 + 2017}}{x^3 - \sqrt{x^6 + 2017}} &= \\ &= \frac{x^6 - (x^6 + 2017)}{x^3 - \sqrt{x^6 + 2017}} = \frac{-2017}{x^3 - \sqrt{x^6 + 2017}}, \text{ więc użyj tego wzoru gdy } x < 0, \\ &\text{a skompletuj z oryginalnego wpisu} \end{aligned}$$

b)  $1 - x^5 - e^{(-x)^5},$

Utrata cyfr znaczących, gdy  $1 \approx x^5$  lub  $1 \approx e^{(-x)^5}$

$$b) \quad 1 - x^5 - e^{(-x)^5} \stackrel{(*)}{=} - \sum_{n=2}^{\infty} \frac{(-x)^{5n}}{n!}$$

$$e^x = \sum_{n=0}^{\infty} \frac{x^n}{n!} = 1 + x + \sum_{n=2}^{\infty} \frac{x^n}{n!}$$

$$e^{(-x)^5} = 1 - x^5 + \sum_{n=2}^{\infty} \frac{(-x)^{5n}}{n!} \quad (*)$$

c)  $\log_3 x - 5,$

Utrata cyfr znaczących, gdy  $\log_3 x \approx 5$

$$c) \quad \log_3 x - 5 \stackrel{①}{=} \log_3 x - \log_3 243 \stackrel{②}{=} \log_3 \left( \frac{x}{243} \right)$$

$$5 = \log_3 a \Leftrightarrow 3^5 = a = 243 \quad ①$$

$$\log_a b - \log_a c = \log_a \left( \frac{b}{c} \right) \quad ②$$

d)  $\sin(x/3) - x/3 + x^3/162 - x^5/29160,$

Utrata cyfr znaczących w wielu miejscach, np. gdy  $\sin(x/3) \approx x/3$

$$d) \quad \sin(x/3) - x/3 + x^3/162 - x^5/29160 \stackrel{(*)}{=} \sum_{n=3}^{\infty} \frac{(-1)^n}{(2n+1)!} (x/3)^{2n+1}$$

$$\sin(x) = \sum_{n=0}^{\infty} \frac{(-1)^n}{(2n+1)!} x^{2n+1} = x - \frac{x^3}{3!} + \frac{x^5}{5!} - \dots$$

$$\sin(x/3) = x/3 - \frac{x^3}{162} + \frac{x^5}{29160} + \sum_{n=3}^{\infty} \frac{(-1)^n}{(2n+1)!} (x/3)^{2n+1} \quad (*)$$


---